Đại học quốc gia TP HCM

Trường Đại học khoa học tự nhiên

Khoa Công nghệ thông tin

Báo cáo đồ án

Linear Regression

<u>Môn Học:</u> Toán ứng dụng và thống kê cho CNTT

Giảng Viên Hướng Dẫn:

Trần Thị Thảo Nhi

Sinh viên thực hiện: Võ Nguyễn Thảo Uyên

MSSV: 23127542

Lớp: 23CLC02

Contents

I. Ý tưởng thực hiện 3

II. Chi tiết thực hiện 3

2.1. Phân tích khám phá dữ liệu 4

2.2. Các mô hình hồi quy tuyến tính 6

2.2.a. Mô hình hồi quy tuyến tính sử dụng cả 5 đặc trưng 6

- Các hàm đã dùng 7
- Các thư viện đã sử dụng 7

2.2.b. Xây dựng mô hình sử dụng duy nhất 1 đặc trưng, tìm mô hình cho kết quả tốt nhất 7

- Các hàm đã sử dụng 7
- Các thư viện đã sử dụng: 8

2.2.c. Xây dựng/thiết kế mô hình, tìm mô hình cho kết quả tốt nhất 8

1) Mô hình 1 (chỉ sử dụng đặc trưng Previous Scores và Hours Studied) 8

2) Mô hình 2 (Sử dụng đặc trưng được tạo ra bằng cách cộng Hours Studied và Sleep Hours) 8

3) Mô hình 3 (Generalized Addictive Model) 9

III. Kết quả và kết luận 10

- Mô hình 2a (sử dụng toàn bộ 5 đặc trưng) 10
- Mô hình 2b (Chỉ sử dụng một đặc trưng) 10
- Các mô hình của yêu cầu 2c 11

IV. Tài liệu tham khảo 12

V. Acknowledgement 12

I. Ý tưởng thực hiện

- Tổng quan về đồ án và mục tiêu của đồ án: Mục tiêu của đồ án là tìm hiểu các yếu tố ảnh hưởng đến thành tích học tập của sinh viên (Academic Student Performance Index). Các yếu tố ảnh hưởng có thể là số giờ học tập/nghiên cứu, hoạt động ngoại khóa, số giờ ngủ, số bài kiểm tra mẫu đã luyện tập...
- Ý tưởng giải quyết: Sử dụng phương pháp Hồi quy tuyến tính (Linear Regression) để xây dựng các mô hình dự đoán điểm của sinh viên dựa trên các đặc trưng (số giờ học tập/nghiên cứu, hoạt động ngoại khóa, số giờ ngủ, số bài kiểm tra mẫu đã luyện tập), sử dụng phương pháp k-fold cross validation để đánh giá độ tin cậy của các mô hình, và sử dụng Feature Engineering để xây dựng một số mô hình.
- Input: Tập p03.train.csv có 9000 mẫu với 5 đặc trưng (features) gồm Hours Studied, Previous Scores, Extracurricular Activities, Sleep Hours, Sample Question Papers Practiced, và 1 target là Performance Index. Tập p03.test.csv có 1000 mẫu với các feature và target tương tự.
- Output: Các mô hình hồi quy tuyến tính có dạng $f = \theta_1 f_1(x_1) + \cdots + \theta_n f_n(x_n)$, và các giá trị MAE (Mean Absolute Error) cho từng mô hình.

II. Chi tiết thực hiện

Các hàm bổ trợ (được lấy từ file lab04.ipynb).

- Lớp OLSLinearRegression bao gồm các hàm: fit(self, X, y), get_params(self), predict(self, X), lần lượt dùng để fit mô hình vào data, lấy các hệ số của mô hình và dự đoán kết quả của mô hình.
- Hàm preprocess(x) dùng để thêm một cột toàn 1 (hệ số của bias) vào dữ liệu input.
- Hàm mae(y, y_hat) dùng để tính giá trị MAE.

2.1. Phân tích khám phá dữ liệu

- **Correlation heatmap**

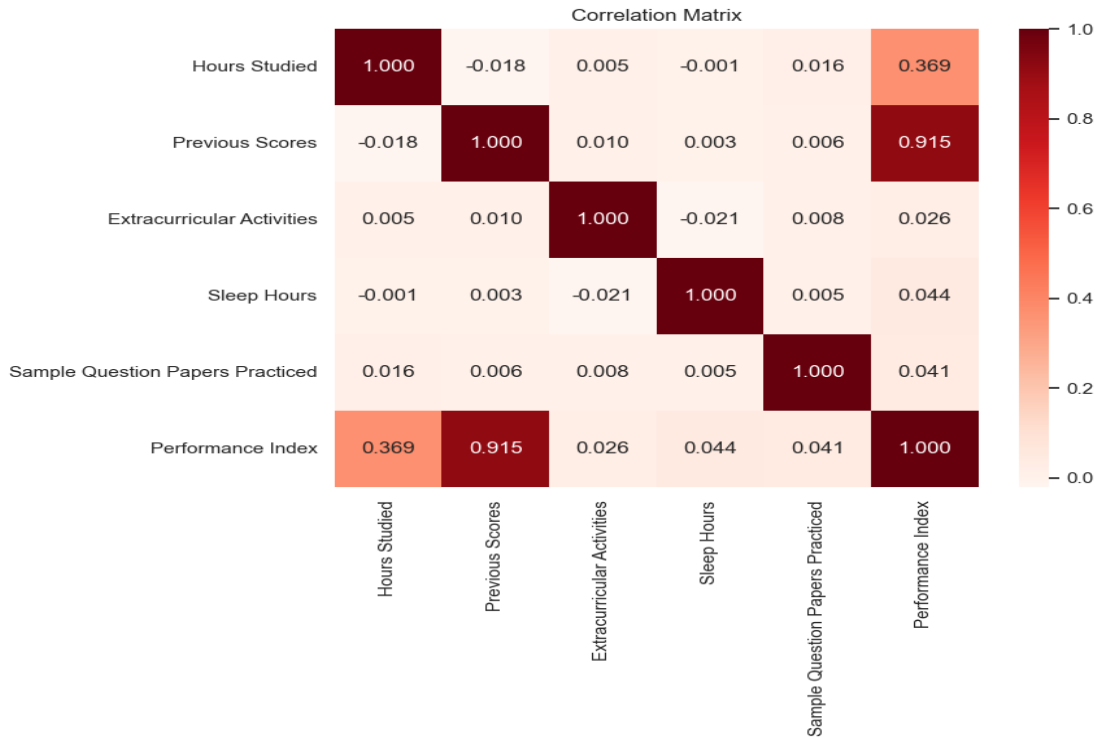

- Ta thấy 2 feature có độ tương quang cao nhất đổi với Perfomance Index là Previous Scores và Hours Studied, có hệ số tương quan lần lượt là 0.915 và 0.369. Các feature khác có tương quan rất ít so với Perfomance Index.

- **Scatter Plot của các feature và Perfomance Index**

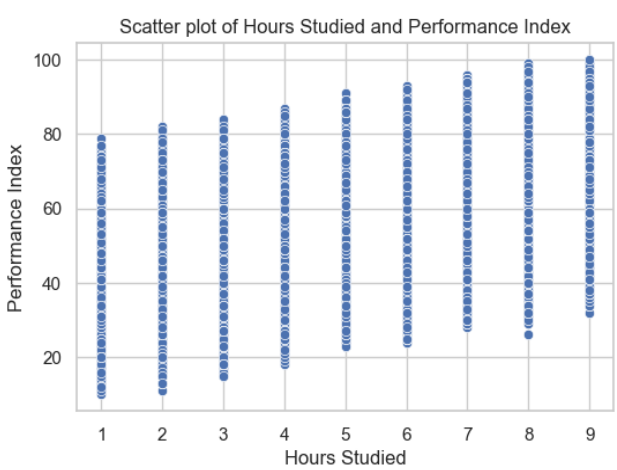

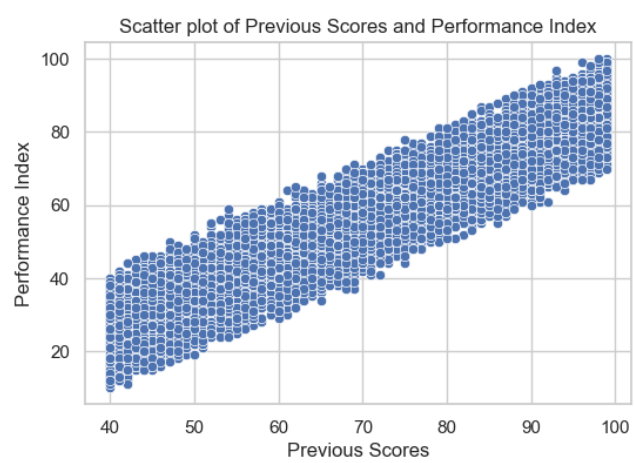

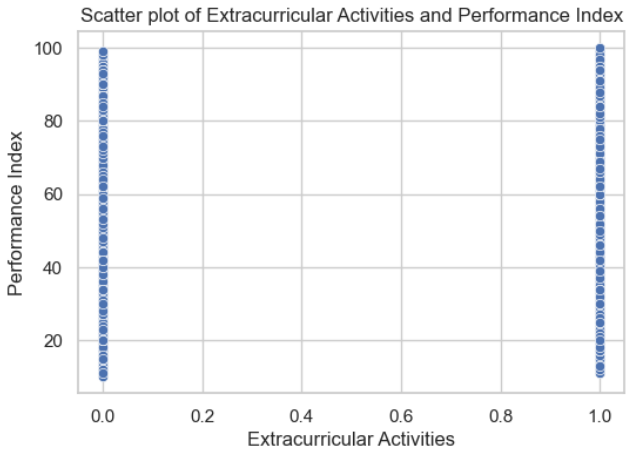

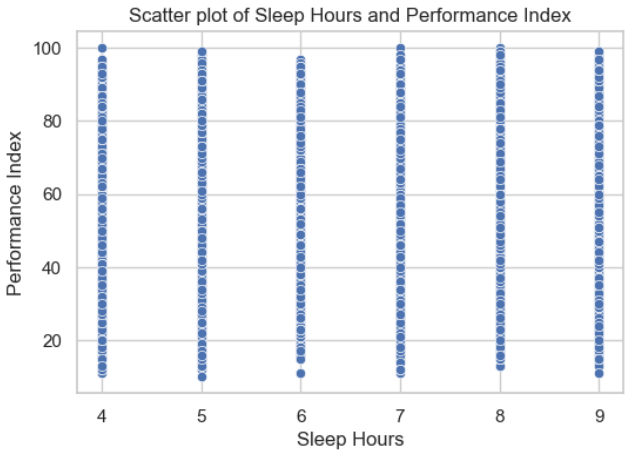

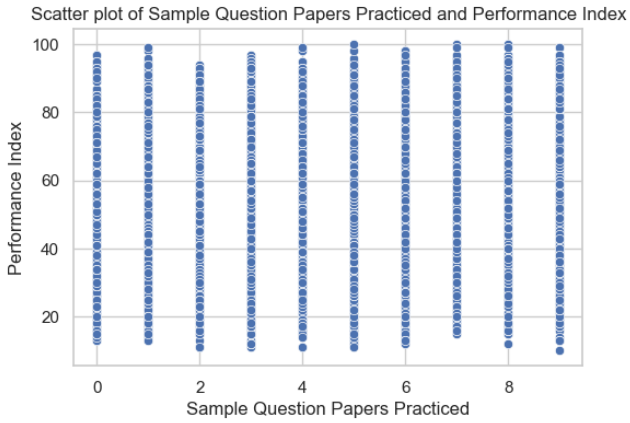

- Ta thấy chỉ có Previous Scores và Hours Studied có vẻ có quan hệ tuyến tính với Performace Index, các feature còn lại gần như không có quan hệ tuyến tính độc lập với Perfomance Index.

  → Từ correlation heatmap và các scatter plot, ta có thể xem xét chỉ sử dụng 2 đặc trưng là Previous Scores và Hours Studied để xây dựng 1 mô hình cho yêu cầu 2c vì đây là 2 feature có ảnh hưởng đến Performance Index nhiều nhất, các đặc trưng còn lại có vẻ như chỉ ảnh hưởng rất ít.

- **Heatmap của Hours Studied và Sleep Hours**

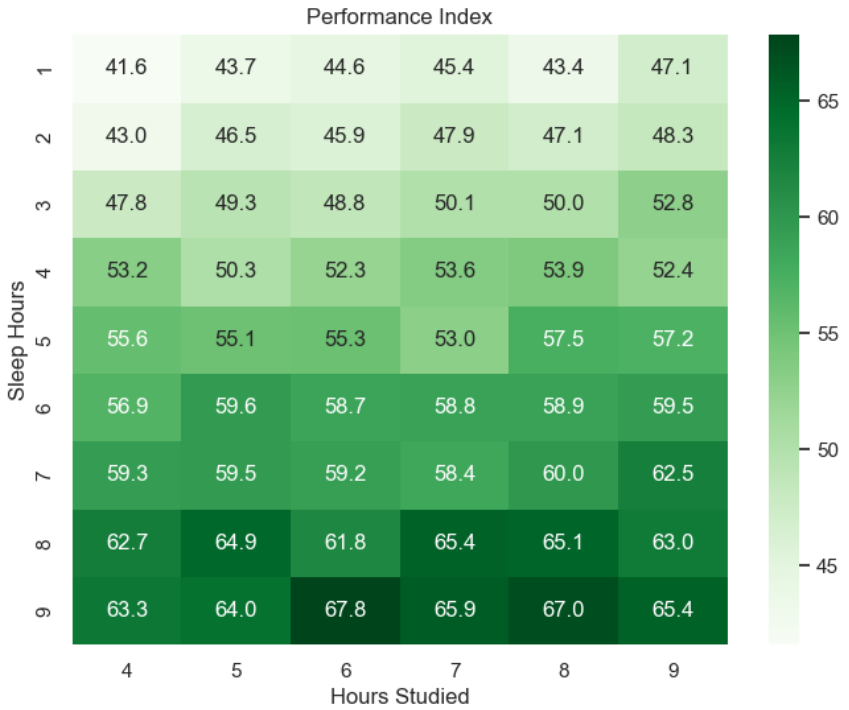

- Heatmap trên cho thấy trung bình Perfomance Index của sinh viên khi học x giờ (trục hoành) và ngủ y giờ (trục tung). Ta thấy, tuy số giờ ngủ độc lập có vẻ không ảnh hưởng nhiều đến Perfomance Index (theo phân tích Correlation Heatmap và Scatter Plot phía trên), nhưng khi kết hợp với đặc trưng số giờ học, các sinh viên có có cùng số giờ học nếu ngủ nhiều hơn sẽ có kết quả tốt hơn. Vì vậy, ta xem xét kết hợp 2 đặc trưng số giờ học và số giờ ngủ thành 1 đặc trưng bằng cách cộng chúng lại với nhau để xây dựng 1 mô hình cho yêu cầu 2c.
- Ngoài ra, theo kiến thức thường thức, một người nên ngủ đủ 8 giờ một ngày để có thể học tập hiệu quả nhất, ngủ ít hơn 8 giờ có thể làm giảm hiệu suất học tập. Vì vậy, ta có thể thêm 1 đặc trưng là sh_below = min{sleep hours – 8, 0} để đo lường số giờ ngủ ít hơn 8 giờ, kết hợp với các đặc trưng gốc để tạo thêm một mô hình có khả năng dự đoán chính xác hơn cho yêu cầu 2c (Generalized Addictive Model). [1]

2.2. Các mô hình hồi quy tuyến tính

2.2.a. Mô hình hồi quy tuyến tính sử dụng cả 5 đặc trưng

- **Các hàm đã dùng:**

  + Hàm preprocess(x): dùng để thêm một cột toàn 1 (hệ số của bias) vào dữ liệu input (để tạo ra một ma trận 9000x6).

  + Lớp OLSLinearRegression bao gồm các hàm: fit(self, X, y), get_params(self), predict(self, X), lần lượt dùng để fit mô hình vào data, lấy các hệ số của mô hình và dự đoán kết quả của mô hình.

  + Hàm mae(y, y_hat) dùng để tính giá trị MAE.

- **Các thư viện đã sử dụng:** không có.

2.2.b. Xây dựng mô hình sử dụng duy nhất 1 đặc trưng, tìm mô hình cho kết quả tốt nhất

- **Các hàm đã sử dụng**

  + cross_validate_one_feature(X, y, feature_name, k=5): Hàm được sử dụng để đánh giá khả năng dự đoán của một đặc trưng duy nhất bằng phương pháp k-fold cross-validation. Hàm sẽ chia dữ liệu thành k phần, huấn luyện mô hình hồi quy tuyến tính (OLS) trên tập huấn luyện và tính MAE trên tập kiểm tra cho từng fold, sau đó trả về giá trị MAE trung bình. Mục tiêu là xác định đặc trưng nào khi dùng riêng lẻ mang lại MAE thấp nhất.

  + Hàm preprocess(x): Tiền xử lý dữ liệu (thêm bias).

  + Lớp OLSLinearRegression bao gồm các hàm: fit(self, X, y), get_params(self), predict(self, X), lần lượt dùng để fit mô hình vào data, lấy các hệ số của mô hình và dự đoán kết quả của mô hình.

  + Hàm mae(y, y_hat) dùng để tính giá trị MAE.

  + Hàm KFold(n_splits=k, shuffle=False) là một hàm của thư viện sklearn.model_selection.Kfold, dùng để chia dữ liệu thành k phần (fold) gần bằng nhau, đặt tham số 'shuffle = False' vì đã shuffle dữ liệu bên ngoài để dùng cho toàn bộ 5 đặc trưng.

  + Hàm shuffle(X_train, y_train, random_state=42): là một hàm của thư viện sklearn.utils, shuffle dữ liệu trước khi cross-validation, đặt random_state = 1 số nào đó để kết quả chạy notebook luôn giống nhau.

+ kf.split(X): là một hàm của thư viện sklearn.model_selection.Kfold, trả về các chỉ số (index) của tập huấn luyện và tập kiểm tra cho từng lần chia.

+ DataFrame(): một hàm từ thư viện pandas dùng để tạo bảng dữ liệu kết quả

- **Các thư viện đã sử dụng:**

  + sklearn.model_selection.Kfold: dùng để sử dụng hàm KFold(n_splits=k, shuffle=False) và hàm kf.split(X) → dùng để thực hiện k-fold cross validation.

  + klearn.utils: dùng để shuffle dữ liệu.

  + pandas: dùng để tạo bảng dữ liệu kết quả.

2.2.c. Xây dựng/thiết kế mô hình, tìm mô hình cho kết quả tốt nhất

1) Mô hình 1 (chỉ sử dụng đặc trưng Previous Scores và Hours Studied)

- **Các hàm đã sử dụng**

  + Hàm cross_validate_two_features(X, y, k=5): Hàm dùng để thực hiện k-fold cross-validation để đánh giá mô hình hồi quy tuyến tính (OLS) khi chỉ sử dụng 2 đặc trưng "Hours Studied" và "Previous Scores", với input X, y, k lần lượt là dataframe, serie và số fold, trả về giá trị MAE trung bình của các lần chạy.

  + Các hàm sau được sử dụng với chức năng tương tự như yêu cầu 2a và 2b: Hàm preprocess(x), Lớp OLSLinearRegression, Hàm mae(y, y_hat), Hàm KFold(n_splits=k, shuffle= False), shuffle(X_train, y_train, random_state=42), và kf.split(X).

- **Các thư viện đã sử dụng:**

  + sklearn.model_selection.Kfold: dùng để sử dụng hàm KFold(n_splits=k, shuffle= False) và hàm kf.split(X)

  + sklearn.utils: shuffle dữ liệu trước khi cross-validation

2) Mô hình 2 (Sử dụng đặc trưng được tạo ra bằng cách cộng Hours Studied và Sleep Hours)

- **Các hàm đã sử dụng**

+ preprocess_custom(df): dùng để tiền xử lý dữ liệu cho mô hình 2, giữ lại ba đặc trưng gốc: "Previous Scores", "Extracurricular Activities", "Sample Question Papers Practiced". Tạo thêm một đặc trưng mới study_sleep_hours bằng tổng của "Sleep Hours" và "Hours Studied", trả. Ghép tất cả đặc trưng này thành 1 ma trận và thêm một cột bias (toàn giá trị 1) ở đầu. Input là dataframe.

+ Hàm cross_validate_custom(X, y, k=5): thực hiện k-fold cross-validation cho mô hình custom sử dụng hàm tiền xử lý preprocess_custom. Trả về giá trị MAE trung bình.

+ Các hàm sau được sử dụng với chức năng tương tự như yêu cầu 2a và 2b: Lớp OLSLinearRegression, Hàm mae(y, y_hat), Hàm KFold(n_splits=k, shuffle= False), shuffle(X_train, y_train, random_state=42), và kf.split(X).

- **Các thư viện đã sử dụng**

+ sklearn.model_selection.Kfold: dùng để sử dụng hàm KFold(n_splits=k, shuffle= False) và hàm kf.split(X)

+ sklearn.utils: shuffle dữ liệu trước khi cross-validation

3) Mô hình 3 (Generalized Addictive Model)

- **Các hàm đã sử dụng**

+ preprocess_GAM(df): Thực hiện tiền xử lý dữ liệu để tạo ma trận đặc trưng cho mô hình hồi quy tuyến tính theo hướng Generalized Additive Model (GAM). Cụ thể, lấy các đặc trưng gốc từ DataFrame (Hours Studied, Previous Scores, Extracurricular Activities, Sleep Hours, Sample Question Papers Practiced). Tạo thêm một đặc trưng phi tuyến sh_below = min(Sleep Hours - 8, 0) để thể hiện mức độ thiếu ngủ nếu số giờ ngủ < 8 (giá trị âm hoặc 0). Ghép tất cả đặc trưng gốc và đặc trưng mới thành một ma trận đặc trưng, đồng thời thêm cột bias, input df là dataframe.

+ Hàm cross_validate_GAM(X, y, k=5): thực hiện k-fold cross-validation cho mô hình sử dụng hàm tiền xử lý preprocess_GAM. Trả về giá trị MAE trung bình.

+ Các hàm sau được sử dụng với chức năng tương tự như yêu cầu 2a và 2b: Lớp OLSLinearRegression, Hàm mae(y, y_hat), Hàm KFold(n_splits=k, shuffle= False), shuffle(X_train, y_train, random_state=42), và kf.split(X).

- **Các thư viện đã sử dụng**

  + sklearn.model_selection.Kfold: dùng để sử dụng hàm KFold(n_splits=k, shuffle= False) và hàm kf.split(X)

  + sklearn.utils: shuffle dữ liệu trước khi cross-validation

III. Kết quả và kết luận

- **Mô hình 2a (sử dụng toàn bộ 5 đặc trưng)**

  + Mô hình xây dựng được trên tập train:

  Student Performance *= −33.169+2.852×Hours Studied+1.018×Previous Scores+0.604×Extracurricular Activities+0.474×Sleep Hour+0.192×Sample Question Papers Practiced*

  + Giá trị MAE trên tập test: 1.59565

  → Giá trị MAE rất nhỏ với kích thước của tập test (1000 mẫu), mô hình hồi quy tuyến tính này có thể dự đoán được Performance Index rất tốt trên tập test.

- **Mô hình 2b (Chỉ sử dụng một đặc trưng)**

  + Bảng MAE ứng với từng đặc trưng

STT	Mô hình với 1 đặc trưng	MAE
1	Hours Studied	15.449
2	Previous Scores	6.618
3	Extracurricular Activities	16.196
4	Sleep Hours	16.187
5	Sample Question Papers Practiced	16.188

→ Nhận xét: Mô hình với đặc trưng Previous Scores có MAE nhỏ nhất, dễ hiểu vì Previous Scores là đặc trưng có độ tương quan so với Performance Index cao nhất và cũng là đặc trưng có quan hệ tuyến tính với Performance Index rõ ràng nhất.

+ Mô hình xây dựng từ đặc trưng Previous Scores:

Student Performance *= −14.989+1.011×Previous Scores*

+ Giá trị MAE trên tập test của mô hình ứng với Previous Scores: 6.544278 → Giá trị gần bằng với MAE trung bình của quá trình cross – validation, mô hình không bị overfit.

- **Các mô hình của yêu cầu 2c**

+ Bảng MAE ứng với từng mô hình:

STT	Mô hình	MAE
1	Sử dụng 2 đặc trưng (Previous Scores, Hours Studied)	1.816
2	Sử dụng đặc trưng tạo ra từ 2 đặc trưng (cộng Hours Studied và Sleep Hours)	3.240
3	Sử dụng Generalized Addictive Model (thêm feature min(Sleep Hours – 8, 0))	1.622

+ Nhận xét:

- **Mô hình 1:** Hai đặc trưng được sử dụng là 2 đặc trưng "mạnh" nhất, có độ tương quan cao nhất cũng như có quan hệ tuyến tính rõ ràng nhất đối với Perfomance Index, nên khi chỉ sử dụng 2 đặc trưng này, MAE của mô hình cũng đã rất thấp → mô hình dự đoán tốt. Tuy nhiên, MAE này vẫn cao hơn so với mô hình sử dụng cả 5 đặc trưng. Từ đó, ta thấy được các đặc trưng khác, tuy không đóng góp nhiều vào Perfomance Index nhưng vẫn có sự ảnh hưởng nhất định.
- **Mô hình 2:** Việc cộng 2 đặc trưng lại để tạo thành 1 đặc trưng làm giảm độ phức tạp của mô hình (từ 5 đặc trưng còn 4 đặc trưng), tuy nhiên đặc trưng được tạo ra (Hours Studied + Sleep Hours) có quan hệ tuyến tính với Perfomance Index không rõ ràng bằng so với đặc trưng Hours Studied, nên việc

cộng 2 đặc trưng lại và bỏ đi Hours Studied đã làm mô hình mất đi một đặc trưng có quan hệ tuyến tính tốt hơn với target. Vì vậy, MAE của mô hình này tăng lên đáng kể so với mô hình 2a.

- **Mô hình 3:** Đây là mô hình có MAE nhỏ nhất, mô hình sử dụng cả 5 đặc trưng gốc và thêm một đặc trưng là min(Sleep Hours – 8, 0) để đo lượng sự thiếu ngủ của sinh viên so với số giờ ngủ được khuyến nghị là 8 giờ, mô hình này thể hiện tốt vì nó không loại bỏ một feature nào, vì tất cả các feature đều có ảnh hưởng đến Perfomance Index (ta thấy được điều này sau khi thử nghiệm mô hình 1 và 2), đồng thời thêm 1 đặc trưng có ý nghĩa trong thực tế (trong phân tích dữ liệu ta cũng thấy sinh viên ngủ nhiều hơn có xu hướng học tốt hơn).

+ Mô hình được xây dựng từ mô hình 3 trên tập train:

Student Performance = −34.648+2.852×Hours Studied+1.018×Previous Score+0.605×Extracurricular Activities+0.554×Sleep Hours+0.192×Sample Question Papers Practiced−0.094 min{Sleep Hours - 8, 0}

+ MAE của mô hình 3 chạy trên tập test: 1.5952 < 1.5957

→ Mô hình này tốt hơn mô hình sử dụng cả 5 đặc trưng một ít. Mô hình này tuy phức tạp hơn mô hình 5 đặc trưng, nhưng không bị overfit.

IV. Tài liệu tham khảo

Phần báo cáo:

[1]. S.Boyd, L. Vandenberghe, Introduction to Applied Linear Algebra Vectors, Matrices, and Least Squares, Chapter 13.3, Cambridge University Press, 2018.

Phần code:

1. N.Kramer, K-Fold Cross-Validation in Scikit-Learn: Tutorial, https://daily.dev/blog/k-fold-cross-validation-in-scikit-learn-tutorial-7e42c%20, Truy cập 12/08/2025. (Hàm cross_validate_one_feature)

V. Acknowledgement

Đồ án có sự trợ giúp của ChatGPT trong phần viết code hàm preprocess_custome và hàm preprocess_GAM.